Briefing: Douglas

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 28/10/2026

Você apresenta: Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas.
Antes de você: Fabio. **Depois de você:** Luiz Felipe.

Sua parte: análise exploratória

Mensagem principal: a taxa é assimétrica (o log corrige), varia muito entre regiões e estados, e nenhum fator sozinho a explica; renda, % pobres e alfabetização medem quase o mesmo, então só a renda entra no modelo.

O que enfatizar

- Daqui em diante, tudo usa os 1.710 municípios do escopo (no mapa, os de fora aparecem em cinza).
- **Resumo:** na taxa, a média (25,0) fica acima da mediana (20,5); a densidade é muito assimétrica e por isso entra em log.
- **Assimetria:** cauda longa à direita (assimetria 1,36); no log fica quase simétrica (−0,49). Isso antecipa a transformação do modelo.
- **Variação entre regiões (mapa e boxplots no mesmo slide):** Norte e Nordeste acima de Sudeste e Sul; Amazônia Legal com mediana 30,1 contra 18,0; na faixa de fronteira, 18,4 contra 20,7. Daí o estado no modelo, e a Amazônia Legal sai por ficar redundante.
- **Correlações:** a maior com o log da taxa é a de % preta/parda (0,56). Na matriz, renda, % pobres e alfabetização se repetem (até 0,92 entre si): multicolinearidade, VIF da renda 27.

Perguntas prováveis

Correlação alta com % preta ou parda quer dizer que a cor causa violência? Não. É associação: reflete desigualdade racial e a concentração da vitimização na população negra, como mostram o Atlas da Violência e a literatura.

Por que o log e não a raiz? Quem decide é o Box-Cox, no slide do Luiz Felipe; aqui só mostramos que a taxa original é assimétrica.

Tirar % pobres e alfabetização não perde informação? Pouca: elas repetem a renda; mantê-las deixaria os coeficientes instáveis e com sinais trocados.

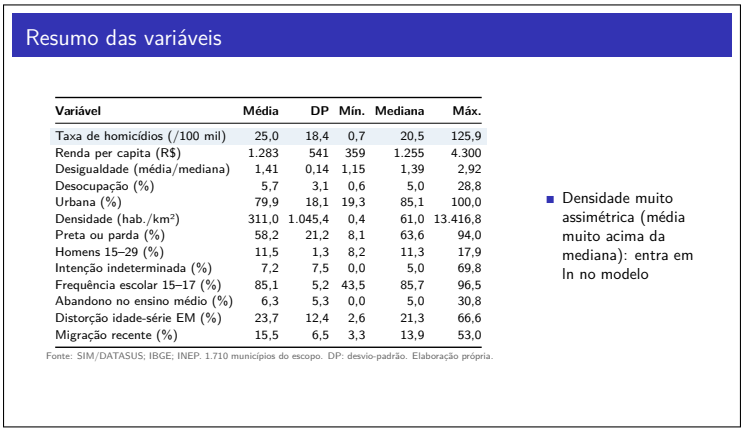
A fronteira não importa? Nos boxplots as medianas são 18,4 (fronteira) e 20,7 (demais), e no modelo ela não é significativa; a seleção de variáveis vai decidir se fica.

Transição

“A relação com a renda tem uma forma especial, que o Luiz Felipe mostra agora.”

Seus slides e o que dizer em cada um

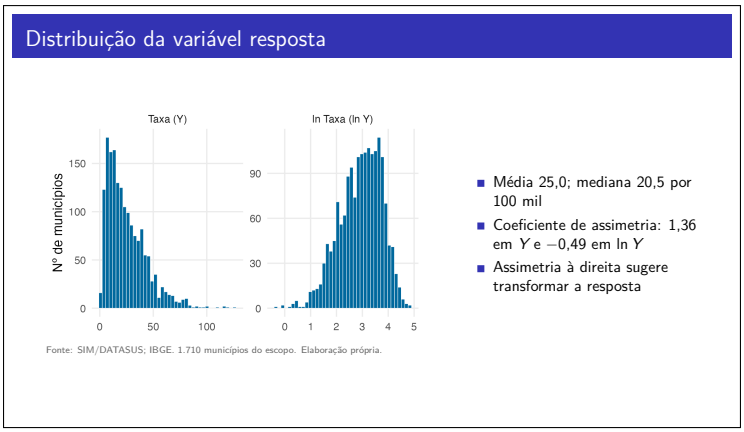
Resumo das variáveis



O que dizer:

- Daqui em diante, só os 1.710 municípios do escopo.
- A tabela resume a resposta e as explicativas do modelo, com escalas e dispersões bem diferentes.
- A densidade é muito assimétrica, com média muito acima da mediana, por isso entra em logaritmo no modelo.

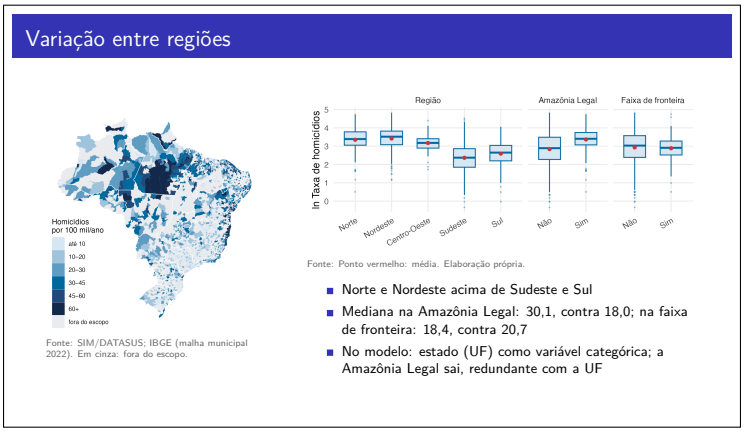
Distribuição da variável resposta



O que dizer:

- O histograma confirma a assimetria da taxa: cauda longa à direita (coeficiente de assimetria 1,36).
- No log a distribuição fica quase simétrica ($-0{,}49$).
- Isso já sugere transformar a resposta, o que o Box-Cox confirma adiante.

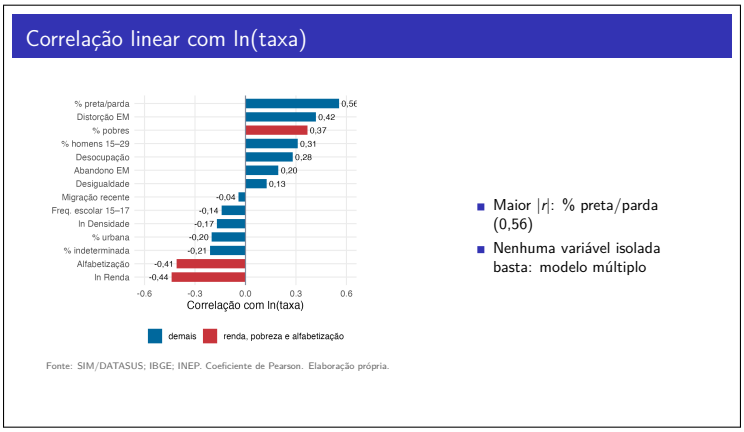
Variação entre regiões



O que dizer:

- O mapa e os boxplots mostram a mesma coisa por dois ângulos: Norte e Nordeste ficam acima de Sudeste e Sul.
- Na Amazônia Legal a mediana é 30,1, contra 18,0 no resto; na faixa de fronteira, 18,4 contra 20,7.
- Como a taxa muda tanto de um lugar para outro, o estado entra no modelo como variável categórica.
- A Amazônia Legal sai: com o estado no modelo, ela fica redundante.

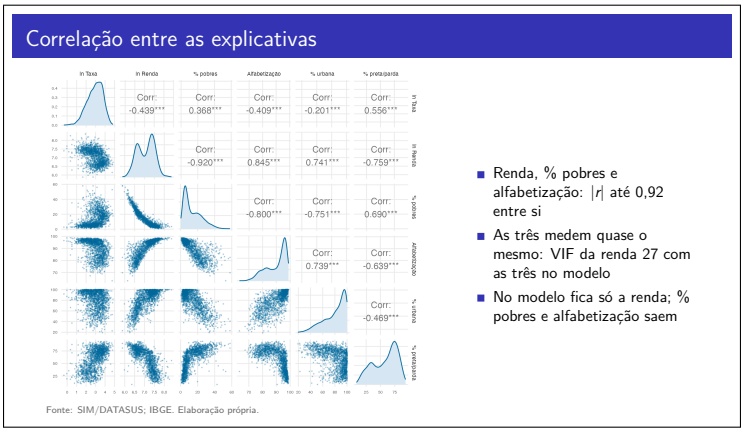
Correlação linear com ln(taxa)



O que dizer:

- Correlação de Pearson de cada explicativa com o log da taxa.
- A maior é a de % preta/parda (0,56).
- Nenhuma variável sozinha basta: precisamos de um modelo múltiplo.

Correlação entre as explicativas



O que dizer:

- A matriz mostra a dispersão e a correlação entre pares de variáveis.
- Renda, % pobres e alfabetização têm correlação entre si de até 0,92: medem quase a mesma coisa.
- Com as três no modelo, o VIF da renda chega a 27.
- Por isso fica só a renda.

O projeto em um minuto

Pergunta: quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, cor ou raça, idade, migração), INEP 2022 (abandono e distorção idade-série no ensino médio), mais estado, Amazônia Legal e faixa de fronteira.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.710 municípios com 20 mil habitantes ou mais.

As decisões e o porquê de cada uma

Decisão	Por quê	Apostila
Violência medida pela taxa de homicídios do SIM	Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023	—
Escopo: municípios com 20 mil hab. ou mais	Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. O escopo fica com 84% da população e nenhum zero	Cap. 1: escopo do modelo
Resposta em ln(taxa)	Box-Cox estimou λ = 0,18 (IC de 0,14 a 0,22); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora (W de 0,92 para 0,98)	Cap. 4: Box-Cox
Só a renda (sem % pobres e alfabetização)	As três medem quase o mesmo: VIF da renda 27 e sinais contraditórios	Cap. 6: multicolinearidade e VIF
Renda e renda², com a renda centralizada	A taxa sobe até a renda média e depois cai (U invertido); centralizar evita a colinearidade entre X e X^2	Cap. 7: modelos polinomiais
Estado (27 UFs) no lugar de região	Estados diferem muito (polícia, facções). Com estado: R^2_a de 0,51 para 0,59, F parcial 15,9 (22 gl). O Durbin-Watson vai de 1,71 para 2,01, mas na ordem do código IBGE (quase alfabética dentro da UF): não mede a correlação entre vizinhos geográficos	Cap. 6 e 7: F parcial, variáveis categóricas
Bloco de educação e migração	Frequência escolar 15–17, abandono, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas. F parcial 46,9 e R^2_a de 0,39 para 0,44	Cap. 6: F parcial
Amazônia Legal fora do modelo	Com o estado no modelo, ela só varia dentro do Maranhão: fica redundante	—
Variáveis frágeis mantidas por enquanto	% homens 15–29, % intenção indeterminada e desocupação saem (ou não) na seleção de variáveis	Cap. 8: seleção
Outliers mantidos	A validação dos dados não achou erro; a apostila manda remover só com evidência de erro	Cap. 4: outliers
Nada fora da apostila	Regra do grupo: técnicas de fora (pesos, modelos espaciais, de contagem) só com decisão do grupo	—

O que o modelo mostra

- O modelo explica 0,59 da variação do ln(taxa) (R^2_a); F global = 62 com 40 e 1.669 gl.
- **Renda em U invertido:** a taxa esperada é máxima com renda per capita de cerca de R$ 1.065 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais % preta ou parda, mais urbanização, mais desigualdade, mais aban-

dono e atraso escolar e mais migração recente; **menos** com mais jovens de 15–17 na escola (efeitos em % na tabela abaixo).

- **Não significativas** no modelo atual: fronteira, densidade e % homens 15–29.

Hip.	Variável	Mudança	Taxa	IC 95%	p
	Renda	—	U invertido	—	<0,001
	% preta ou parda	+10 pontos	+19,6%	[+15,8; +23,6]	<0,001
	% urbana	+10 pontos	+9,4%	[+6,5; +12,3]	<0,001
H2	Distorção idade-série (EM)	+10 pontos	+6,1%	[+1,5; +10,9]	0,009
H2	Frequência escolar 15–17	+5 pontos	−5,7%	[−8,3; −3,1]	<0,001
H2	Abandono no ensino médio	+5 pontos	+4,3%	[+0,6; +8,2]	0,022
H1	Desigualdade	+0,1	+3,2%	[+0,7; +5,9]	0,013
H3	Migração recente	+5 pontos	+3,0%	[+0,6; +5,5]	0,014
	Desocupação	+1 ponto	−1,4%	[−2,5; −0,2]	0,024
	% intenção indeterminada	+1 ponto	−1,2%	[−1,5; −0,8]	<0,001

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 110 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** (C_p, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- **Correlação entre vizinhos:** o Durbin-Watson na ordem do código não a avalia; falta verificar se resíduos de municípios vizinhos se parecem.
- Testadas e deixadas de fora (não ajudam): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

Quem fala o quê

Quem	Slides, na ordem
Kauan	Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com todos os municípios do país; Questão de pesquisa e hipóteses
Fabio	Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Escopo: municípios com 20 mil habitantes ou mais
Douglas	Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas
Luiz Felipe	Relação não linear com a renda; Transformação da resposta (Box-Cox); Especificação do modelo; Construção do modelo em blocos
Willian	Estimativas: efeito de cada variável na taxa; Efeito da renda previsto pelo modelo; Diagnóstico dos resíduos; Considerações e próximos passos; Obrigado

Glossário rápido

Escopo do modelo	Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam.
Box-Cox	Procedimento que escolhe a potência λ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log.
R^2_a **(ajustado)**	Fração da variação explicada, com penalidade por variável a mais.
Teste F **parcial**	Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda.
VIF	Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave.
Durbin-Watson	Testa se resíduos consecutivos, na ordem dos dados, se parecem. Perto de 2 = sem correlação. Só mede vizinhança se a ordem dos dados for geográfica.
Breusch-Pagan	Testa se a variância dos resíduos é constante.
Shapiro-Wilk (W**)**	Testa a normalidade dos resíduos; perto de 1 = mais normal.
Outlier	Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$.
Modelo espacial autorregressivo	Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila.
Modelo multinível	Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila.