Briefing: Douglas

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 11/11/2026

Você apresenta: Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas.
Antes de você: Fabio. **Depois de você:** Luiz Felipe.

Sua parte: análise exploratória

Mensagem principal: a taxa é assimétrica à direita (o que pede uma transformação), varia muito entre regiões, e nenhum fator sozinho a explica; renda, % pobres e alfabetização medem quase o mesmo, então só a renda entra no modelo.

O que enfatizar

- Daqui em diante, tudo usa os 1.622 municípios do escopo (no mapa, os de fora aparecem em cinza).
- **Resumo:** as variáveis têm escalas e dispersões bem diferentes; a densidade tinha desvio-padrão muito acima da média: saem os 88 municípios fora dos 95% centrais da sua região e ela entra no modelo em log e padronizada.
- **Assimetria (histograma da taxa):** metade dos municípios fica entre 11,1 e 35,3, mas há uma cauda longa à direita (assimetria 1,37, positiva), que puxa a média (25,0) para cima da mediana (20,4). Isso antecipa a transformação do modelo.
- **Variação entre regiões (mapa e boxplot no mesmo slide):** Norte e Nordeste acima de Sudeste e Sul. Daí a região no modelo; a Amazônia Legal sai porque a maior parte dela é a própria região Norte.
- **Correlações:** a maior com o log da taxa é a de ln Renda (0,45). Na matriz, renda, % pobres e alfabetização se repetem (até 0,93 entre si): multicolinearidade, VIF da renda 19 (com ln renda sem padronizar; padronizar não muda o VIF).

Perguntas prováveis

Por que o log e não a raiz? Quem decide é o Box-Cox, no slide do Luiz Felipe; aqui só mostramos que a taxa original é assimétrica.

Tirar % pobres e alfabetização não perde informação? Pouca: elas repetem a renda; mantê-las deixaria os coeficientes instáveis e com sinais trocados.

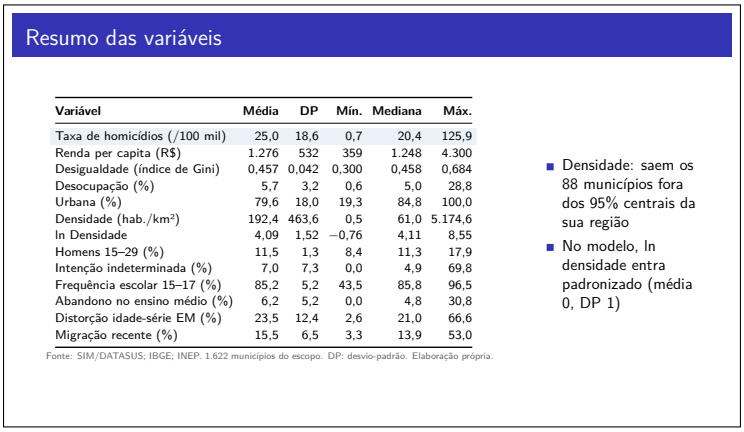
A fronteira não importa? No modelo ela não é significativa: com a região no modelo, boa parte do efeito regional já é captada; a seleção de variáveis vai decidir se ela fica.

Transição

“A relação com a renda tem uma forma especial, que o Luiz Felipe mostra agora.”

Seus slides e o que dizer em cada um

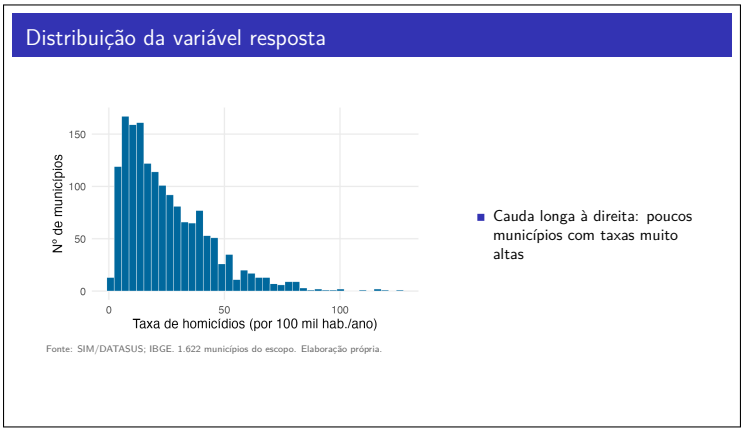
Resumo das variáveis



O que dizer:

- Daqui em diante, só os 1.622 municípios do escopo.
- A tabela resume a resposta e as explicativas do modelo, com escalas e dispersões bem diferentes.
- A densidade tinha desvio-padrão muito acima da média.
- Por isso saem os 88 municípios fora dos 95% centrais da sua região, e ela entra no modelo em logaritmo e padronizada.

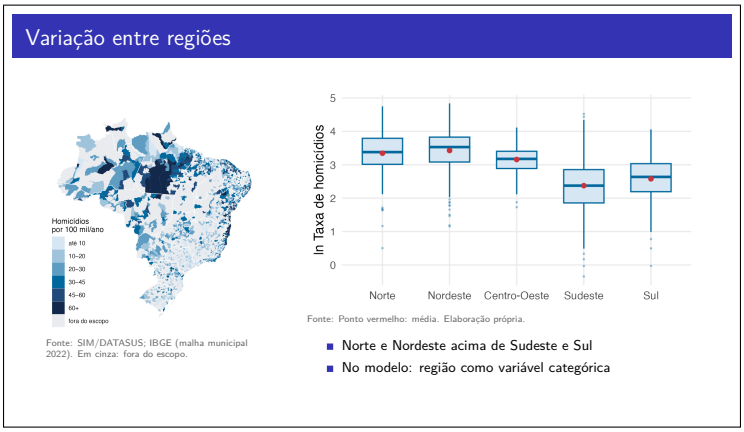
Distribuição da variável resposta



O que dizer:

- O histograma mostra a assimetria da taxa: metade dos municípios fica entre 11,1 e 35,3 homicídios por 100 mil, mas há uma cauda longa à direita, com poucos municípios muito violentos.
- Por isso a média (25,0) fica acima da mediana (20,4), e o coeficiente de assimetria é 1,37, positivo.
- Essa assimetria sugere transformar a resposta antes do modelo; o Box-Cox, adiante, indica qual transformação usar.

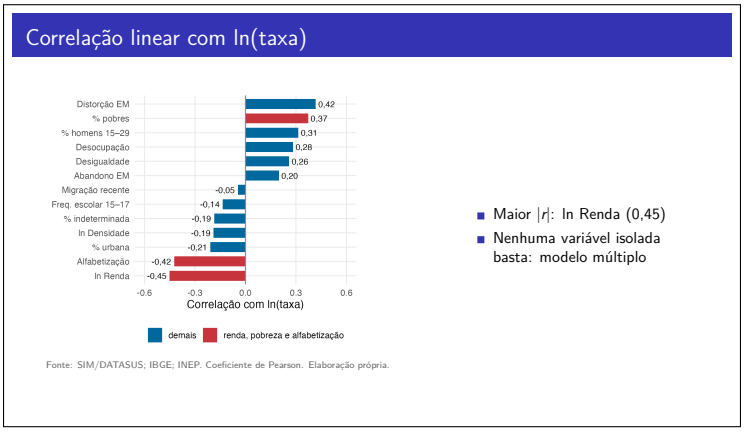
Variação entre regiões



O que dizer:

- O mapa e os boxplots mostram a mesma coisa por dois ângulos: Norte e Nordeste ficam acima de Sudeste e Sul.
- Como a taxa muda tanto de um lugar para outro, a região entra no modelo como variável categórica.
- A Amazônia Legal fica de fora: a maior parte dela é a própria região Norte.

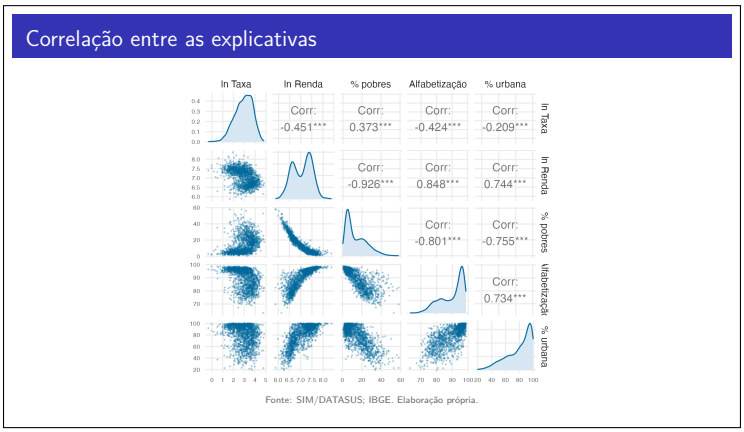
Correlação linear com ln(taxa)



O que dizer:

- Correlação de Pearson de cada explicativa com o log da taxa.
- A maior é a de ln Renda (0,45).
- Nenhuma variável sozinha basta: precisamos de um modelo múltiplo.

Correlação entre as explicativas



O que dizer:

- A matriz mostra a dispersão e a correlação entre pares de variáveis.
- Renda, % pobres e alfabetização têm correlação entre si de até 0,93: medem quase a mesma coisa.
- Com as três no modelo, o VIF da renda chega a 19.
- Esse VIF usa ln renda sem padronizar; padronizar não muda o valor.
- Por isso fica só a renda.

O projeto em um minuto

Pergunta: quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, idade, migração), INEP 2022 (abandono e distorção idade-série no ensino médio), mais região e faixa de fronteira.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.622 municípios com 20 mil habitantes ou mais, sem os 88 extremos de densidade.

As decisões e o porquê de cada uma

Decisão	Por quê	Apostila
Violência medida pela taxa de homicídios do SIM	Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023	—
Escopo: municípios com 20 mil hab. ou mais	Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. A partir desse porte não há nenhum zero	Cap. 1: escopo do modelo
Densidade sem extremos e padronizada	Pedido da professora: o desvio-padrão da densidade era muito maior que a média. Cada município recebe o percentil da sua densidade dentro da sua região. Ficam os que estão entre os percentis 2,5 e 97,5 (os 95% centrais); saem 88 e ficam 1.622 (66% da população). ln densidade entra padronizado	Cap. 1: resumos da distribuição; Cap. 6: padronização
Resposta em ln(taxa)	Box-Cox estimou λ = 0,22 (IC de 0,17 a 0,26); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora (W de 0,93 para 0,99)	Cap. 4: Box-Cox
Só a renda (sem % pobres e alfabetização)	As três medem quase o mesmo: VIF da renda 19 e sinais contraditórios	Cap. 6: multicolinearidade e VIF
Renda e renda², com a renda centralizada	A taxa sobe até uma renda de cerca de R$ 819 (abaixo da renda mediana) e depois cai (U invertido); centralizar evita a colinearidade entre X e X^2	Cap. 7: modelos polinomiais
Renda mantida, depois de comparar o modelo com e sem ela	Pedido da professora, por causa do VIF da renda (8,5). F parcial da renda 84,3 (2 gl); sem ela o R^2_a cai de 0,45 para 0,40. A desigualdade continua significativa sem a renda; migração e densidade deixam de ser	Cap. 6: multicolinearidade e F parcial
Região (5 classes) como variável categórica	Pedido da professora: agrupar os municípios por região do Brasil. Entram 4 indicadoras, com o Sudeste de referência. É o bloco com maior ganho de R^2_a. **A escolha entre região e estado está em aberto**: um slide mostra os dois modelos lado a lado (com estado: 40 parâmetros, R^2_a 0,56, VIF máximo 10,8)	Cap. 6 e 7: F parcial, variáveis categóricas
Bloco de educação e migração	Frequência escolar 15–17, abandono, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas em uma versão anterior do modelo. F parcial 41,5 e R^2_a de 0,33 para 0,38	Cap. 6: F parcial
Amazônia Legal fora do modelo	A maior parte dela é a própria região Norte, que já está no modelo	—
Variáveis não significativas mantidas por enquanto	faixa de fronteira, % homens 15–29, abandono no ensino médio, desocupação: saem (ou não) na seleção de variáveis	Cap. 8: seleção
Outliers mantidos	A validação dos dados não achou erro; a apostila manda remover só com evidência de erro	Cap. 4: outliers
Fora da apostila só com aviso	Regra do grupo: técnicas de fora (pesos, modelos espaciais, de contagem) só com decisão do grupo. O que já é de fora está listado no Apêndice C do deck: três itens vieram da revisão da professora (Gini, corte por percentil, padronização) e quatro são escolhas do grupo	—

O que o modelo mostra

- O modelo explica 0,45 da variação do ln(taxa) (R^2_a); F global = 80 com 17 e 1.604 gl.
- **Renda em U invertido:** a taxa esperada é máxima com renda per capita de cerca de R$ 819 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais desigualdade, mais urbanização, mais atraso escolar e mais migração recente; **menos** com mais jovens de 15–17 na escola (efeitos em % na tabela abaixo).
- **Não significativas** no modelo atual: faixa de fronteira, % homens 15–29, abandono no ensino médio, desocupação.

Hip.	Variável	Mudança	Taxa	IC 95%	p
	Renda	—	U invertido	—	$<$0,001
H1	Desigualdade (Gini)	+0,05	$+$16,2%	[$+$11,3; $+$21,4]	$<$0,001
H2	Distorção idade-série (EM)	+10 pontos	$+$10,9%	[$+$6,8; $+$15,3]	$<$0,001
	% urbana	+10 pontos	$+$10,4%	[$+$7,2; $+$13,7]	$<$0,001
H2	Frequência escolar 15–17	+5 pontos	$-$7,8%	[$-$10,5; $-$4,9]	$<$0,001
	ln densidade	+1 DP	$+$5,4%	[$+$0,7; $+$10,3]	0,023
H3	Migração recente	+5 pontos	$+$4,6%	[$+$1,8; $+$7,5]	0,001
	% intenção indeterminada	+1 ponto	$-$0,8%	[$-$1,3; $-$0,4]	$<$0,001

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 57 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** (C_p, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- Testadas em uma versão anterior do modelo e deixadas de fora (não ajudaram): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

Quem fala o quê

Quem	Slides, na ordem
Kauan	Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com municípios brasileiros; Questão de pesquisa e hipóteses
Fabio	Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil por região
Douglas	Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas
Luiz Felipe	Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado
Willian	Estimativas: efeito de cada variável na taxa; Efeito da renda previsto pelo modelo; Diagnóstico: linearidade e variância; Diagnóstico: normalidade; Diagnóstico: resumo dos testes; Modelo com e sem a renda; Considerações e próximos passos; Obrigado

Glossário rápido

Escopo do modelo	Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam.
Box-Cox	Procedimento que escolhe a potência λ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log.
R^2_a **(ajustado)**	Fração da variação explicada, com penalidade por variável a mais.
Teste F **parcial**	Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda.
VIF	Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave.
Breusch-Pagan	Testa se a variância dos resíduos é constante.
Shapiro-Wilk (W**)**	Testa a normalidade dos resíduos; perto de 1 = mais normal.
Outlier	Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$.
Modelo espacial autorregressivo	Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila.
Modelo multinível	Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila.