# Briefing: Fabio

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 11/11/2026

**Você apresenta:** Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil por região.
**Antes de você:** Kauan. **Depois de você:** Douglas.

## Sua parte: dados, medida de violência e limitações

**Mensagem principal:** usamos três fontes oficiais, ligadas pelo código do município; a violência é medida pela taxa de homicídios do SIM, a estatística mais confiável e comparável entre municípios; e os próprios dados nos obrigaram a restringir o estudo aos municípios com 20 mil habitantes ou mais.

### O que enfatizar

- **Fontes:** SIM/DATASUS (óbitos), Censo 2022 (características dos municípios; renda e trabalho vêm da amostra do Censo) e INEP 2022 (abandono e distorção idade-série no ensino médio).
- **Por que homicídios:** é o indicador 16.1.1 do ODS 16; é a estatística de violência local mais confiável do país e anda junto com os outros crimes (Murray, Cerqueira e Kahn, 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10).
- **Como medimos:** agressão (X85–Y09) e intervenção legal (Y35–Y36), pela residência da vítima, média de 2021 a 2023, por 100 mil habitantes.
- **Explicativas:** cinco blocos (A a E), os mesmos da construção do modelo. A região entra como 4 indicadoras, com o Sudeste como referência.
- **Limitações:** as quatro em linguagem simples. A última (municípios pequenos) define o escopo: nos menores, muitos zeros e oscilação grande só pelo acaso, por isso ficamos com os municípios com 20 mil hab. ou mais; sem os 88 extremos de densidade de cada região (percentis 2,5 a 97,5), são 1.622 (66% da população). O escopo vale para **toda** a análise, exploratória e modelo.

### Perguntas prováveis

**Por que não usar dados da polícia?** O SIM cobre todos os municípios com a mesma codificação (CID-10); o homicídio é a medida de violência local mais confiável do país (Murray et al., 2013).

**Por que município de residência e não de ocorrência?** Porque o denominador é a população residente; assim taxa e população falam das mesmas pessoas.

**Por que 20 mil, e não 10 mil ou 50 mil?** É a partir desse porte que nenhum município tem taxa zero e a oscilação por acaso cai para ±23%. Com 50 mil perderíamos boa parte do país; com 10 mil ainda há zeros.

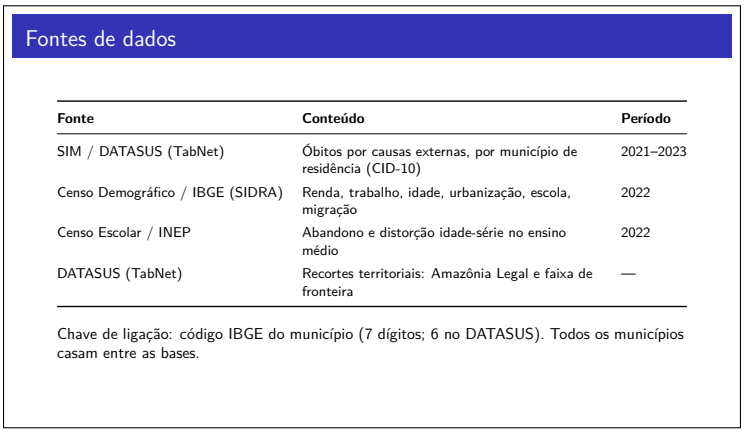
**Como vocês têm o Gini por município, se o IBGE não publica?** Calculamos pelas classes de renda do Censo 2022 (pessoas de 14 anos ou mais em cada faixa de renda domiciliar per capita), pela área sob a curva de Lorenz. Para conferir, aplicamos o mesmo cálculo aos 27 estados: a correlação com o Gini oficial é 0,995 e o erro médio é 0,003. É uma aproximação: ignora a desigualdade dentro de cada faixa.

### Transição

Ao terminar as limitações: "Com o escopo definido, o Douglas mostra o que os dados revelam antes de qualquer modelo."

## Seus slides e o que dizer em cada um

## Fontes de dados



Fontes de dados

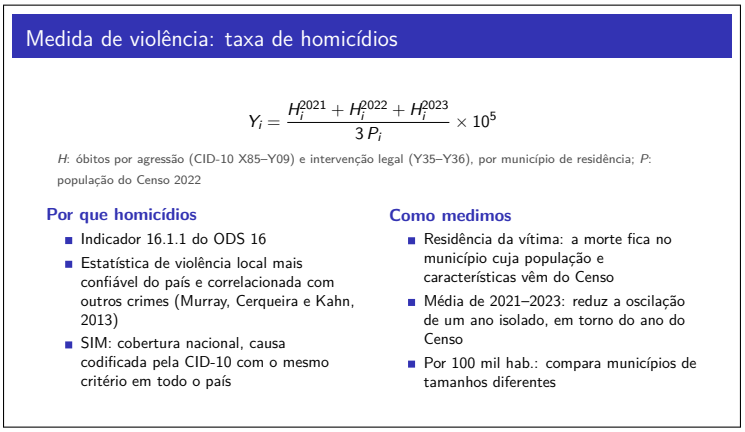
| Fonte | Conteúdo | Período |
|---|---|---|
| SIM / DATASUS (TabNet) | Óbitos por causas externas, por município de residência (CID-10) | 2021–2023 |
| Censo Demográfico / IBGE (SIDRA) | Renda, trabalho, idade, urbanização, escola, migração | 2022 |
| Censo Escolar / INEP | Abandono e distorção idade-série no ensino médio | 2022 |
| DATASUS (TabNet) | Recortes territoriais: Amazônia Legal e faixa de fronteira | — |

Chave de ligação: código IBGE do município (7 dígitos; 6 no DATASUS). Todos os municípios casam entre as bases.

**O que dizer:**

- Resposta: SIM/DATASUS, registro oficial de óbitos do Ministério da Saúde, por município de residência.
- Explicativas: Censo 2022, pela API do SIDRA (inclui frequência escolar e migração), e INEP 2022 (Censo Escolar: abandono e distorção idade-série no ensino médio).
- Amazônia Legal e faixa de fronteira vêm dos recortes territoriais do DATASUS.
- As bases se ligam pelo código IBGE do município, e todos os municípios casam.

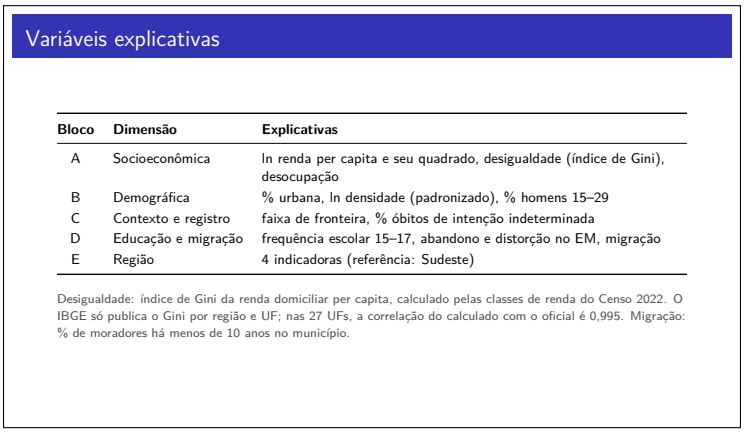
## Medida de violência: taxa de homicídios




**O que dizer:**

- Para medir a violência usamos a taxa de homicídios: óbitos por agressão (CID-10 X85–Y09) e intervenção legal (Y35–Y36), somados de 2021 a 2023 e divididos por 3 vezes a população do Censo, por 100 mil habitantes.
- Escolhemos o homicídio por três motivos: é o indicador oficial do ODS 16.1.1; segundo Murray, Cerqueira e Kahn (2013), é a estatística de violência local mais confiável do país e anda junto com os outros crimes; e o SIM cobre todo o país com a causa codificada pela CID-10, o mesmo critério em todos os municípios.
- Contamos pela residência da vítima, para que a morte fique no município cujas características vêm do Censo; usamos a média de três anos para reduzir a oscilação de um ano isolado; e dividimos pela população para comparar municípios de tamanhos diferentes.

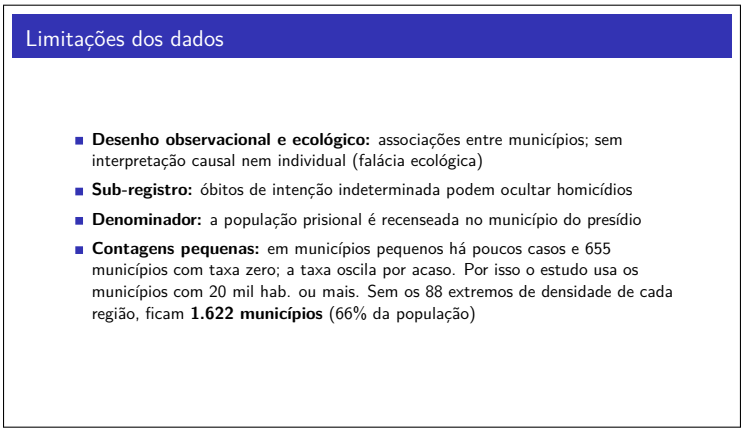
## Variáveis explicativas




**O que dizer:**

- As explicativas estão organizadas nos cinco blocos que usamos para montar o modelo: socioeconômico, demográfico, contexto e registro, educação e migração, e região.
- Desigualdade: índice de Gini, calculado por nós a partir das classes de renda do Censo 2022, porque o IBGE só publica o Gini por região e por estado.
- Nos 27 estados, o Gini calculado tem correlação de 0,995 com o oficial, e o erro médio é de 0,003.
- Distorção idade-série: % de alunos do ensino médio com 2 anos ou mais de atraso.
- Migração recente: % de moradores há menos de 10 anos no município.
- Faixa de fronteira: 150 km ao longo da fronteira terrestre.
- A região entra como 4 indicadoras, com o Sudeste como referência.

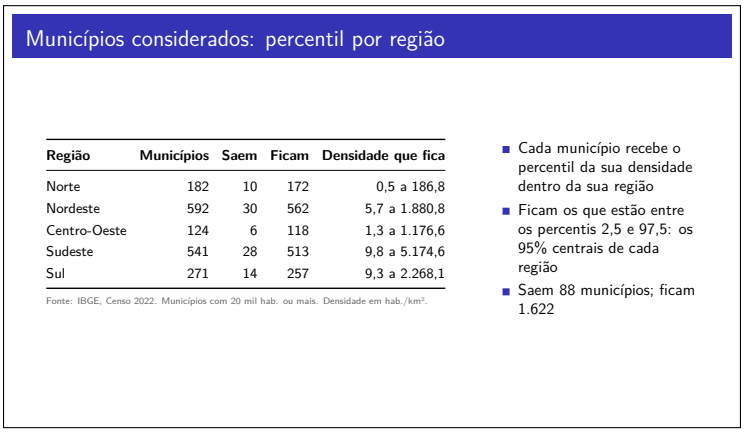
## Limitações dos dados




**O que dizer:**

- É um estudo observacional e ecológico: mostra associação entre municípios, não causa, e não vale para indivíduos (falácia ecológica).
- Usamos homicídios registrados: onde muitas mortes ficam como 'intenção indeterminada', parte dos homicídios fica escondida.
- O Censo conta os presos como moradores do município do presídio.
- E, nos municípios pequenos, o homicídio é raro: poucos casos e muitos zeros (655 municípios sem nenhum homicídio) fazem a taxa oscilar por acaso.
- Por isso toda a análise usa os municípios com 20 mil habitantes ou mais (apostila, cap. 1: escopo do modelo).
- A pedido da professora, saem também os 88 municípios com densidade extrema dentro da sua região, como mostra o próximo slide.
- Ficam 1.622 municípios, 66% da população, nenhum com taxa zero.

## Municípios considerados: percentil por região




**O que dizer:**

- Para decidir quais municípios considerar, calculamos o percentil da densidade de cada município dentro da sua região.
- O percentil diz a posição do município: 50 é o do meio da região.
- Ficamos com os que estão entre os percentis 2,5 e 97,5, ou seja, os 95% centrais de cada região.
- A tabela mostra, por região, quantos saem e a faixa de densidade que fica.
- No total saem 88 municípios e ficam 1.622.

## O projeto em um minuto

**Pergunta:** quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, idade, migração), INEP 2022 (abandono e distorção idade-série no ensino médio), mais região e faixa de fronteira.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.622 municípios com 20 mil habitantes ou mais, sem os 88 extremos de densidade.

## As decisões e o porquê de cada uma

| Decisão | Por quê | Apostila |
|---|---|---|
| Violência medida pela taxa de homicídios do SIM | Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023 | — |
| Escopo: municípios com 20 mil hab. ou mais | Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. A partir desse porte não há nenhum zero | Cap. 1: escopo do modelo |
| Densidade sem extremos e padronizada | Pedido da professora: o desvio-padrão da densidade era muito maior que a média. Cada município recebe o percentil da sua densidade dentro da sua região. Ficam os que estão entre os percentis 2,5 e 97,5 (os 95% centrais); saem 88 e ficam 1.622 (66% da população). ln densidade entra padronizado | Cap. 1: resumos da distribuição; Cap. 6: padronização |
| Resposta em ln(taxa) | Box-Cox estimou $\lambda$ = 0,22 (IC de 0,17 a 0,26); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora ($W$ de 0,93 para 0,99) | Cap. 4: Box-Cox |
| Só a renda (sem % pobres e alfabetização) | As três medem quase o mesmo: VIF da renda 19 e sinais contraditórios | Cap. 6: multicolinearidade e VIF |
| Renda e renda², com a renda centralizada | A taxa sobe até a renda média e depois cai (U invertido); centralizar evita a colinearidade entre $X$ e $X^2$ | Cap. 7: modelos polinomiais |
| Renda mantida, depois de comparar o modelo com e sem ela | Pedido da professora, por causa do VIF da renda (8,5). $F$ parcial da renda 84,3 (2 gl); sem ela o $R^2_a$ cai de 0,45 para 0,40. A desigualdade continua significativa sem a renda; migração e densidade deixam de ser | Cap. 6: multicolinearidade e $F$ parcial |
| Região (5 classes) como variável categórica | Pedido da professora: agrupar os municípios por região do Brasil. Entram 4 indicadoras, com o Sudeste de referência. É o bloco com maior ganho de $R^2_a$. **A escolha entre região e estado está em aberto**: um slide mostra os dois modelos lado a lado (com estado: 40 parâmetros, $R^2_a$ 0,56, VIF máximo 10,8) | Cap. 6 e 7: $F$ parcial, variáveis categóricas |
| Bloco de educação e migração | Frequência escolar 15–17, abandono, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas. $F$ parcial 41,5 e $R^2_a$ de 0,33 para 0,38 | Cap. 6: $F$ parcial |
| Amazônia Legal fora do modelo | A maior parte dela é a própria região Norte, que já está no modelo | — |
| Variáveis frágeis mantidas por enquanto | % homens 15–29, % intenção indeterminada e desocupação saem (ou não) na seleção de variáveis | Cap. 8: seleção |
| Outliers mantidos | A validação dos dados não achou erro; a apostila manda remover só com evidência de erro | Cap. 4: outliers |
| Nada fora da apostila | Regra do grupo: técnicas de fora (pesos, modelos espaciais, de contagem) só com decisão do grupo | — |

## O que o modelo mostra

- O modelo explica 0,45 da variação do ln(taxa) ($R^2_a$); $F$ global = 80 com 17 e 1.604 gl.
- **Renda em U invertido:** a taxa esperada é máxima com renda per capita de cerca de R$ 819 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais desigualdade, mais urbanização, mais atraso escolar e mais migração recente; **menos** com mais jovens de 15–17 na escola (efeitos em % na tabela abaixo).
- **Não significativas** no modelo atual: faixa de fronteira, % homens 15–29, abandono no ensino médio, desocupação.

| Hip. | Variável | Mudança | Taxa | IC 95% | $p$ |
|---|---|---|---|---|---|
| | Renda | — | U invertido | — | <0,001 |
| H1 | Desigualdade (Gini) | +0,05 | +16,2% | [+11,3; +21,4] | <0,001 |
| H2 | Distorção idade-série (EM) | +10 pontos | +10,9% | [+6,8; +15,3] | <0,001 |
| | % urbana | +10 pontos | +10,4% | [+7,2; +13,7] | <0,001 |
| H2 | Frequência escolar 15–17 | +5 pontos | −7,8% | [−10,5; −4,9] | <0,001 |
| | ln densidade | +1 DP | +5,4% | [+0,7; +10,3] | 0,023 |
| H3 | Migração recente | +5 pontos | +4,6% | [+1,8; +7,5] | 0,001 |
| | % intenção indeterminada | +1 ponto | −0,8% | [−1,3; −0,4] | <0,001 |

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

## O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 57 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** ($C_p$, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- Testadas e deixadas de fora (não ajudam): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

## Quem fala o quê

| Quem | Slides, na ordem |
|---|---|
| **Kauan** | Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com todos os municípios do país; Questão de pesquisa e hipóteses |
| **Fabio** | Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil por região |
| **Douglas** | Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas |
| **Luiz Felipe** | Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado |
| **Willian** | Estimativas: efeito de cada variável na taxa; Efeito da renda previsto pelo modelo; Diagnóstico: linearidade e variância; Diagnóstico: normalidade; Diagnóstico: resumo dos testes; Modelo com e sem a renda; Considerações e próximos passos; Obrigado |

## Glossário rápido

| | |
|---|---|
| **Escopo do modelo** | Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam. |
| **Box-Cox** | Procedimento que escolhe a potência $\lambda$ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log. |
| $R^2_a$ **(ajustado)** | Fração da variação explicada, com penalidade por variável a mais. |
| **Teste** $F$ **parcial** | Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda. |
| **VIF** | Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave. |
| **Breusch-Pagan** | Testa se a variância dos resíduos é constante. |
| **Shapiro-Wilk (**$W$**)** | Testa a normalidade dos resíduos; perto de 1 = mais normal. |
| **Outlier** | Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$. |
| **Modelo espacial autorregressivo** | Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila. |
| **Modelo multinível** | Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila. |