Briefing: Luiz Felipe

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 11/11/2026

Você apresenta: Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos.
Antes de você: Douglas. **Depois de você:** Willian.

Sua parte: renda em U, transformação e construção do modelo

Mensagem principal: a relação com a renda é em U invertido; a resposta entra em log (Box-Cox); e o modelo foi montado em blocos, cada um testado pelo F parcial.

O que enfatizar

- **Renda:** nos dados, o pico fica perto de R$ 796; os mais violentos são os de renda média, não os mais pobres. Por isso entram renda e renda² (modelo polinomial).
- **Box-Cox:** λ estimado 0,22 (IC 0,17 a 0,26); usamos o log, simples de interpretar. Normalidade: W de 0,93 para 0,99. No slide seguinte, mostrar os gráficos dos resíduos antes e depois: com o log, a dispersão fica mais uniforme e os pontos ficam mais perto da reta.
- **Equação:** cada termo corresponde a uma decisão já mostrada: log da taxa (Box-Cox), renda e renda² (U invertido), os blocos A a D e a região (variação entre regiões).
- **Blocos:** todos entram; educação e migração dão F parcial 41,5; o maior ganho de R^2_a vem da região.

Perguntas prováveis

O λ estimado não é 0, e o 0 está fora do IC; por que usar o log? A apostila recomenda usar um valor de fácil interpretação perto do estimado; o log permite ler os efeitos em %. Dizemos no slide que a escolha é por interpretabilidade.

O que é cada termo da equação? r é o ln da renda centralizado, $\mathbf{x}$ são as outras explicativas, D são as indicadoras de região e ε é o erro, suposto normal, independente e de variância constante.

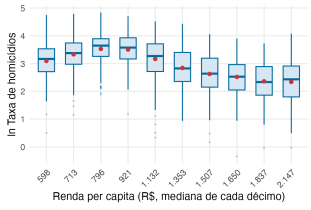
Por que região e não estado? A professora pediu para agrupar os municípios por região. São 4 indicadoras em vez de 26, e o modelo fica mais simples de ler. O estado explicava mais, mas com muito mais parâmetros.

Transição

"Com o modelo montado, o Willian mostra o que ele diz e como checamos as hipóteses."

Seus slides e o que dizer em cada um

Relação não linear com a renda



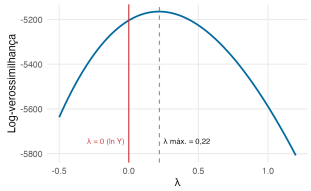
Fonte: SIM/DATASUS; IBGE. Décimos de renda per capita. Elaboração própria.

- Taxa maior nos décimos intermediários (pico perto de R$ 796)
- Forma de U invertido
- No modelo: polinômio de 2ª ordem na renda

Relação não linear com a renda

Cada caixa é um décimo dos municípios por renda. Nos dados, a taxa é maior nos décimos de renda média (pico perto de R$ 796) e cai nos dois extremos: isso pede um termo de renda ao quadrado (modelo polinomial de 2a ordem).

Transformação da resposta (Box-Cox)



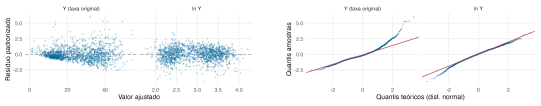
Fonte: Elaboração própria; modelo com todas as explicativas e a região.

- Box e Cox (1964): $\hat{\lambda} = 0{,}22$; IC 95%: [0,17; 0,26]
- Adotado $\lambda = 0$ (ln *Y*), por interpretabilidade (efeitos lidos em %), embora fique fora do IC
- Shapiro-Wilk: *W* de 0,93 (*Y*) para 0,99 (ln *Y*)

Transformação da resposta (Box-Cox)

Box-Cox no modelo múltiplo: lambda estimado 0,22, com IC 95% de 0,17 a 0,26. O zero fica fora do intervalo; mesmo assim adotamos o logaritmo (lambda = 0), porque a apostila recomenda um valor de fácil interpretação próximo do estimado e o log permite ler os efeitos em %. A normalidade dos resíduos melhora (W de 0,93 para 0,99).

Resíduos antes e depois da transformação



Fonte: Elaboração própria. Resíduos padronizados do modelo com todas as explicativas e a região.

- Com *Y*: a dispersão cresce com o valor ajustado e a cauda direita foge da reta
- Com ln *Y*: dispersão mais uniforme e pontos mais próximos da reta

Resíduos antes e depois da transformação

Estes são os gráficos dos resíduos antes e depois da transformação. Com a taxa original, a dispersão dos resíduos cresce com o valor ajustado, em forma de funil, e no gráfico de quantis a cauda direita foge da reta. Com o logaritmo, a dispersão fica mais uniforme e os pontos ficam mais próximos da reta. Por isso seguimos com ln(taxa).

Especificação do modelo

$$\ln Y_i = \beta_0 + \beta_1 r_i + \beta_2 r_i^2 + \mathbf{x}_i^{\top}\boldsymbol{\delta} + \sum_{k=1}^{4} \gamma_k D_{ik} + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} N(0, \sigma^2)$$

- r_i: ln da renda per capita, centrada na média (reduz a correlação entre r e r^2 de 0,9995 para $-0{,}13$)
- $\mathbf{x}_i$: as demais 11 explicativas dos blocos A a D
- D_{ik}: indicadora da região k (referência: Sudeste)
- Mínimos quadrados ordinários; $n = 1.622$ municípios e 18 parâmetros

Especificação do modelo

Esta é a equação do modelo. A resposta é o log da taxa. A renda entra centralizada na média e ao quadrado; centralizar reduz a correlação entre renda e renda ao quadrado de 0,9995 para −0,13. O vetor x reúne as outras 11 explicativas dos blocos A a D, e as D são as 4 indicadoras de região, com o Sudeste de referência. Estimamos por mínimos quadrados ordinários, com 1.622 municípios e 18 parâmetros, supondo erros independentes, normais e de variância constante; o diagnóstico verifica essas hipóteses.

Construção do modelo em blocos

Bloco	gl	*F* parcial	*p*	R^2_{aj}
A: renda e desigualdade	—	—	—	0,28
B: + demografia	3	19,3	<0,001	0,30
C: + fronteira e registro	2	43,6	<0,001	0,33
D: + educação e migração	4	41,5	<0,001	0,38
E: + região	**4**	**52,9**	**<0,001**	**0,45**

Fonte: Elaboração própria. *F* parcial pelas somas de quadrados extras.

- H_0: os coeficientes do bloco são nulos; rejeitada em todos os blocos
- Maior ganho de R^2_{aj} com a região (bloco E)

Construção do modelo em blocos

Entramos com as variáveis em blocos e testamos cada um pelo F parcial (somas de quadrados extras); a hipótese nula é que os coeficientes do bloco são todos zero, e ela é rejeitada em todos. O bloco de educação e migração entra com F parcial 41,5 (R^2 ajustado de 0,33 para 0,38). O maior ganho de R^2 ajustado vem da região, o que confirma a diferença entre lugares vista na exploratória.

O projeto em um minuto

Pergunta: quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, idade, migração), INEP 2022 (abandono e distorção idade-série no ensino médio), mais região e faixa de fronteira.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.622 municípios com 20 mil habitantes ou mais, sem os 88 extremos de densidade.

As decisões e o porquê de cada uma

Decisão	Por quê	Apostila
Violência medida pela taxa de homicídios do SIM	Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023	—
Escopo: municípios com 20 mil hab. ou mais	Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. A partir desse porte não há nenhum zero	Cap. 1: escopo do modelo
Densidade sem extremos e padronizada	Pedido da professora: o desvio-padrão da densidade era muito maior que a média. Cada município recebe o percentil da sua densidade dentro da sua região. Ficam os que estão entre os percentis 2,5 e 97,5 (os 95% centrais); saem 88 e ficam 1.622 (66% da população). ln densidade entra padronizado	Cap. 1: resumos da distribuição; Cap. 6: padronização
Resposta em ln(taxa)	Box-Cox estimou λ = 0,22 (IC de 0,17 a 0,26); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora (W de 0,93 para 0,99)	Cap. 4: Box-Cox
Só a renda (sem % pobres e alfabetização)	As três medem quase o mesmo: VIF da renda 19 e sinais contraditórios	Cap. 6: multicolinearidade e VIF
Renda e renda², com a renda centralizada	A taxa sobe até a renda média e depois cai (U invertido); centralizar evita a colinearidade entre X e X^2	Cap. 7: modelos polinomiais
Renda mantida, depois de comparar o modelo com e sem ela	Pedido da professora, por causa do VIF da renda (8,5). F parcial da renda 84,3 (2 gl); sem ela o R^2_a cai de 0,45 para 0,40. A desigualdade continua significativa sem a renda; migração e densidade deixam de ser	Cap. 6: multicolinearidade e F parcial
Região (5 classes) como variável categórica	Pedido da professora: agrupar os municípios por região do Brasil. Entram 4 indicadoras, com o Sudeste de referência. É o bloco com maior ganho de R^2_a	Cap. 6 e 7: F parcial, variáveis categóricas
Bloco de educação e migração	Frequência escolar 15–17, abandono, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas. F parcial 41,5 e R^2_a de 0,33 para 0,38	Cap. 6: F parcial
Amazônia Legal fora do modelo	A maior parte dela é a própria região Norte, que já está no modelo	—
Variáveis frágeis mantidas por enquanto	% homens 15–29, % intenção indeterminada e desocupação saem (ou não) na seleção de variáveis	Cap. 8: seleção
Outliers mantidos	A validação dos dados não achou erro; a apostila manda remover só com evidência de erro	Cap. 4: outliers
Nada fora da apostila	Regra do grupo: técnicas de fora (pesos, modelos espaciais, de contagem) só com decisão do grupo	—

O que o modelo mostra

- O modelo explica 0,45 da variação do ln(taxa) (R^2_a); F global = 80 com 17 e 1.604 gl.
- **Renda em U invertido:** a taxa esperada é máxima com renda per capita de cerca de R$ 819 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais desigualdade, mais urbanização, mais atraso escolar e mais migração recente; **menos** com mais jovens de 15–17 na escola (efeitos em % na tabela abaixo).
- **Não significativas** no modelo atual: faixa de fronteira, % homens 15–29, abandono no ensino

médio, desocupação.

Hip.	Variável	Mudança	Taxa	IC 95%	p
	Renda	—	U invertido	—	<0,001
H1	Desigualdade (Gini)	+0,05	+16,2%	[+11,3; +21,4]	<0,001
H2	Distorção idade-série (EM)	+10 pontos	+10,9%	[+6,8; +15,3]	<0,001
	% urbana	+10 pontos	+10,4%	[+7,2; +13,7]	<0,001
H2	Frequência escolar 15–17	+5 pontos	−7,8%	[−10,5; −4,9]	<0,001
	ln densidade	+1 DP	+5,4%	[+0,7; +10,3]	0,023
H3	Migração recente	+5 pontos	+4,6%	[+1,8; +7,5]	0,001
	% intenção indeterminada	+1 ponto	−0,8%	[−1,3; −0,4]	<0,001

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 57 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** (C_p, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- Testadas e deixadas de fora (não ajudam): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

Quem fala o quê

Quem	Slides, na ordem
Kauan	Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com todos os municípios do país; Questão de pesquisa e hipóteses
Fabio	Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil por região
Douglas	Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas
Luiz Felipe	Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos
Willian	Estimativas: efeito de cada variável na taxa; Efeito da renda previsto pelo modelo; Diagnóstico: linearidade e variância; Diagnóstico: normalidade; Diagnóstico: resumo dos testes; Modelo com e sem a renda; Considerações e próximos passos; Obrigado

Glossário rápido

Escopo do modelo	Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam.
Box-Cox	Procedimento que escolhe a potência λ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log.
R^2_a **(ajustado)**	Fração da variação explicada, com penalidade por variável a mais.
Teste F **parcial**	Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda.
VIF	Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave.
Breusch-Pagan	Testa se a variância dos resíduos é constante.
Shapiro-Wilk (W**)**	Testa a normalidade dos resíduos; perto de 1 = mais normal.
Outlier	Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$.
Modelo espacial autorregressivo	Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila.
Modelo multinível	Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila.