Briefing: Luiz Felipe

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 11/11/2026

Você apresenta: Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado.
Antes de você: Douglas. **Depois de você:** Willian.

Sua parte: renda em U, transformação e construção do modelo

Mensagem principal: a relação com a renda é em U invertido; a resposta entra em log (Box-Cox); e o modelo foi montado em blocos, cada um testado pelo F parcial.

O que enfatizar

- **Renda:** nos dados, o pico fica perto de R$ 873; os mais violentos não são os mais pobres nem os mais ricos: são os do 3º décimo de renda, abaixo da renda mediana. Por isso entram renda e renda² (modelo polinomial).
- **Box-Cox:** λ estimado 0,23 (IC 0,17 a 0,28); usamos o log, simples de interpretar. Normalidade: W de 0,94 para 0,99. No slide seguinte, mostrar os gráficos dos resíduos antes e depois: com o log, a dispersão fica mais uniforme e os pontos ficam mais perto da reta.
- **Equação:** cada termo corresponde a uma decisão já mostrada: log da taxa (Box-Cox), renda e renda² (U invertido), os blocos A a D e a região (variação entre regiões).
- **Blocos:** todos entram; educação e migração dão F parcial 40,8; o maior ganho de R^2_a vem da região.
- **Região ou estado:** mostrar os dois modelos lado a lado. O estado explica mais (R^2_a 0,63 contra 0,54), mas usa 39 parâmetros e o VIF máximo sobe para 10,5. As três hipóteses valem nos dois. Dizer que escolhemos a região e que o modelo com estado fica como comparação.

Perguntas prováveis

O λ estimado não é 0, e o 0 está fora do IC; por que usar o log? A apostila recomenda usar um valor de fácil interpretação perto do estimado; o log permite ler os efeitos em %. Dizemos no slide que a escolha é por interpretabilidade.

O que é cada termo da equação? r é o ln da renda centralizado, $\mathbf{x}$ são as outras explicativas, D são as indicadoras de região e ε é o erro, suposto normal, independente e de variância constante.

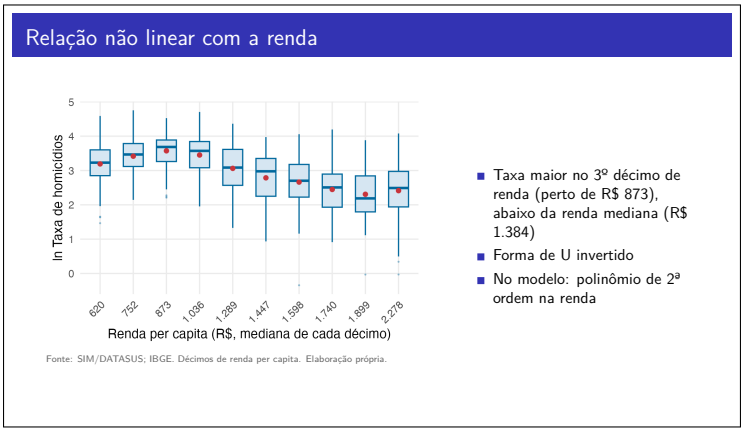
Região ou estado: qual vocês vão usar? A região. A professora pediu para agrupar por região, e esse é o modelo dos outros slides. O modelo com estado fica como comparação. O estado explica mais (F parcial 14,1 com 22 gl), mas tem 39 parâmetros, VIF máximo de 10,5 e 5 estados com menos de 10 municípios.

Transição

“Com o modelo montado, o Willian mostra o que ele diz e como checamos as hipóteses.”

Seus slides e o que dizer em cada um

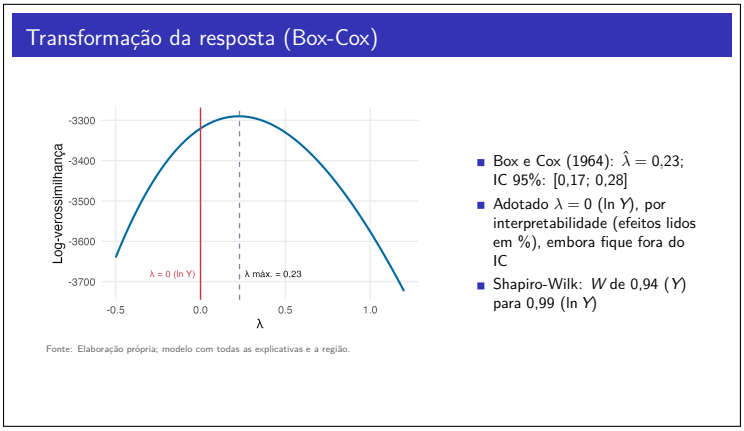
Relação não linear com a renda



O que dizer:

- Cada caixa é um décimo dos municípios por renda.
- Nos dados, a taxa é maior no 3º décimo de renda (perto de R$ 873), abaixo da renda mediana, e cai para os dois lados: isso pede um termo de renda ao quadrado (modelo polinomial de 2a ordem).

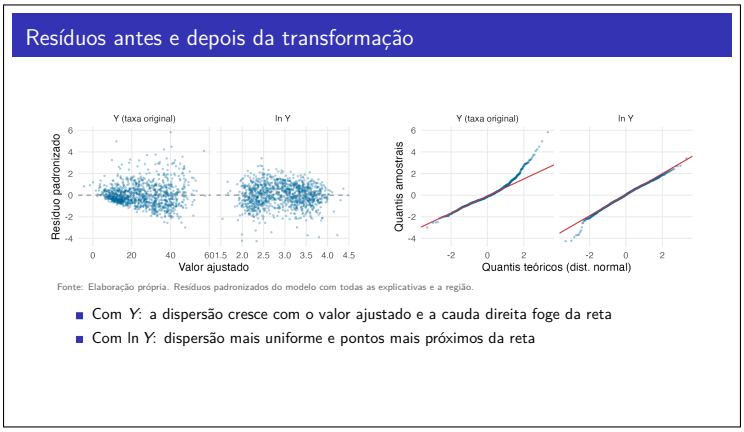
Transformação da resposta (Box-Cox)



O que dizer:

- Box-Cox no modelo múltiplo: lambda estimado 0,23, com IC 95% de 0,17 a 0,28.
- O zero fica fora do intervalo; mesmo assim adotamos o logaritmo (lambda = 0), porque a apostila recomenda um valor de fácil interpretação próximo do estimado e o log permite ler os efeitos em %.
- A normalidade dos resíduos melhora (W de 0,94 para 0,99).

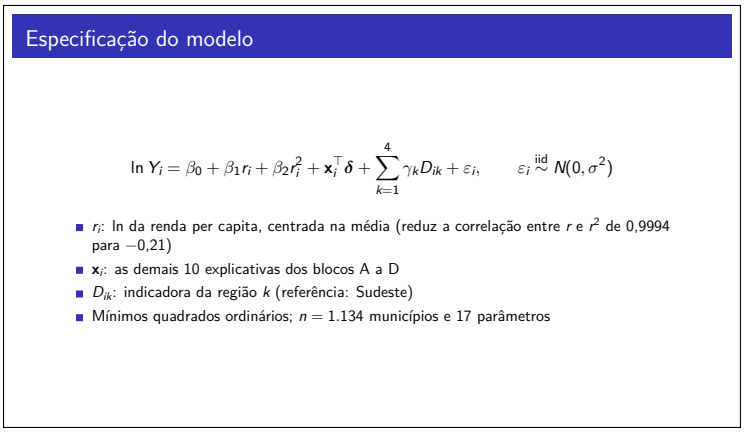
Resíduos antes e depois da transformação



O que dizer:

- Estes são os gráficos dos resíduos antes e depois da transformação.
- Com a taxa original, a dispersão dos resíduos cresce com o valor ajustado, em forma de funil, e no gráfico de quantis a cauda direita foge da reta.
- Com o logaritmo, a dispersão fica mais uniforme e os pontos ficam mais próximos da reta.
- Por isso seguimos com ln(taxa).

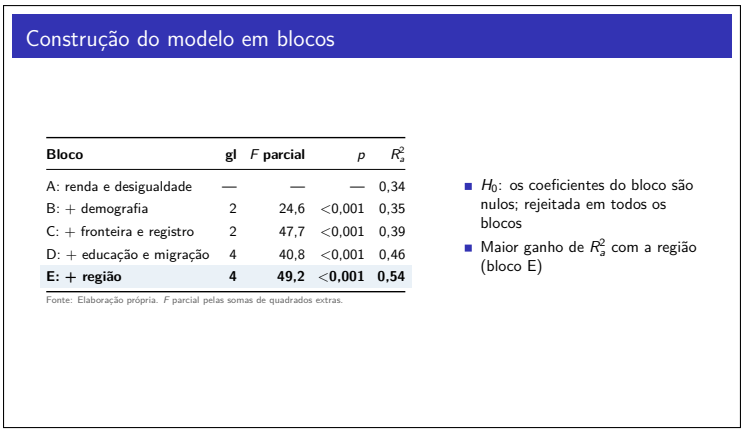
Especificação do modelo



O que dizer:

- Esta é a equação do modelo.
- A resposta é o log da taxa.
- A renda entra centralizada na média e ao quadrado; centralizar reduz a correlação entre renda e renda ao quadrado de 0,9994 para $-0{,}21$.
- O vetor x reúne as outras 10 explicativas dos blocos A a D, e as D são as 4 indicadoras de região, com o Sudeste de referência.
- Estimamos por mínimos quadrados ordinários, com 1.134 municípios e 17 parâmetros, supondo erros independentes, normais e de variância constante; o diagnóstico verifica essas hipóteses.

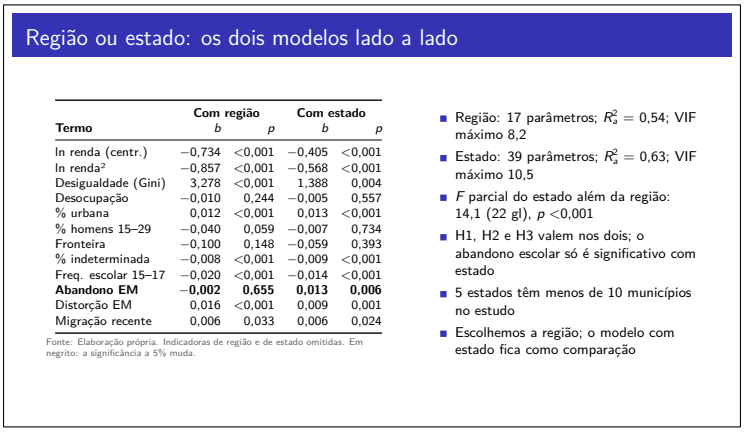
Construção do modelo em blocos



O que dizer:

- Entramos com as variáveis em blocos e testamos cada um pelo F parcial (somas de quadrados extras); a hipótese nula é que os coeficientes do bloco são todos zero, e ela é rejeitada em todos.
- O bloco de educação e migração entra com F parcial 40,8 (R^2 ajustado de 0,39 para 0,46).
- O maior ganho de R^2 ajustado vem da região, o que confirma a diferença entre lugares vista na exploratória.

Região ou estado: os dois modelos lado a lado



O que dizer:

- Aqui estão os dois modelos lado a lado: com a região e com o estado.
- O modelo com estado tem 39 parâmetros e R² ajustado de 0,63; o modelo com região tem 17 parâmetros e R² ajustado de 0,54.
- O F parcial do estado além da região é 14,1 com 22 gl: o estado explica mais.
- Em troca, o VIF máximo sobe para 10,5 e 5 estados têm menos de 10 municípios no estudo.
- As três hipóteses valem nos dois modelos; o abandono escolar só é significativo com estado.
- Escolhemos a região: o modelo é mais simples e as três hipóteses valem nos dois.
- O modelo com estado fica como comparação.

O projeto em um minuto

Pergunta: quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, idade, migração), INEP 2022 (abandono e distorção idade-série no ensino médio), mais região e faixa de fronteira.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.134 municípios com 30 mil habitantes ou mais.

As decisões e o porquê de cada uma

Decisão	Por quê	Apostila
Violência medida pela taxa de homicídios do SIM	Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023	—
Escopo: municípios com 30 mil hab. ou mais	Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. O corte fica perto do percentil 80 da população (pedido da professora: percentil por município): a partir dele não há nenhum zero e há pelo menos 20 homicídios esperados em 3 anos. Ficam 1.134 municípios (77% da população)	Cap. 1: escopo do modelo
Densidade fora do modelo	Pedido da professora: padronizar a densidade e tirar os extremos, porque o desvio-padrão era muito maior que a média. Com o corte de 30 mil hab., a densidade (em ln, padronizada) não é significativa: F = 1,74, p = 0,19. Ela sai do modelo, e não é preciso cortar municípios por densidade	Cap. 6: F parcial e padronização
Resposta em ln(taxa)	Box-Cox estimou λ = 0,23 (IC de 0,17 a 0,28); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora (W de 0,94 para 0,99)	Cap. 4: Box-Cox
Só a renda (sem % pobres e alfabetização)	As três medem quase o mesmo: VIF da renda 16 e sinais contraditórios	Cap. 6: multicolinearidade e VIF
Renda e renda², com a renda centralizada	A taxa sobe até uma renda de cerca de R$ 818 (abaixo da renda mediana) e depois cai (U invertido); centralizar evita a colinearidade entre X e X^2	Cap. 7: modelos polinomiais
Renda mantida, depois de comparar o modelo com e sem ela	Pedido da professora, por causa do VIF da renda (8,2). F parcial da renda 77,4 (2 gl); sem ela o R^2_a cai de 0,54 para 0,47. Sem a renda, a desigualdade e a migração deixam de ser significativas	Cap. 6: multicolinearidade e F parcial
Região (5 classes) como variável categórica	Pedido da professora: agrupar os municípios por região do Brasil. Entram 4 indicadoras, com o Sudeste de referência. É o bloco com maior ganho de R^2_a. **Entre região e estado, o grupo escolheu a região**: um slide mostra os dois modelos lado a lado, e o modelo com estado fica como comparação (com estado: 39 parâmetros, R^2_a 0,63, VIF máximo 10,5)	Cap. 6 e 7: F parcial, variáveis categóricas
Bloco de educação e migração	Frequência escolar 15–17, abandono, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas em uma versão anterior do modelo. F parcial 40,8 e R^2_a de 0,39 para 0,46	Cap. 6: F parcial
Amazônia Legal fora do modelo	A maior parte dela é a própria região Norte, que já está no modelo	—
Variáveis não significativas mantidas por enquanto	faixa de fronteira, % homens 15–29, abandono no ensino médio, desocupação: saem (ou não) na seleção de variáveis	Cap. 8: seleção
Outliers mantidos	A validação dos dados não achou erro; a apostila manda remover só com evidência de erro	Cap. 4: outliers
Fora da apostila só	Regra do grupo: técnicas de fora (pesos, modelos espaciais, de	—

O que o modelo mostra

- O modelo explica 0,54 da variação do ln(taxa) (R^2_a); F global = 83 com 16 e 1.117 gl.
- **Renda em U invertido:** a taxa esperada é máxima com renda per capita de cerca de R$ 818 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais desigualdade, mais urbanização, mais atraso escolar e mais migração recente; **menos** com mais jovens de 15–17 na escola (efeitos em % na tabela abaixo).
- **Não significativas** no modelo atual: faixa de fronteira, % homens 15–29, abandono no ensino médio, desocupação.

Hip.	Variável	Mudança	Taxa	IC 95%	p
	Renda	—	U invertido	—	$<$0,001
H1	Desigualdade (Gini)	+0,05	$+$17,8%	[$+$12,2; $+$23,7]	$<$0,001
H2	Distorção idade-série (EM)	+10 pontos	$+$16,8%	[$+$11,8; $+$22,1]	$<$0,001
	% urbana	+10 pontos	$+$13,1%	[$+$9,4; $+$16,9]	$<$0,001
H2	Frequência escolar 15–17	+5 pontos	$-$9,7%	[$-$13,1; $-$6,2]	$<$0,001
H3	Migração recente	+5 pontos	$+$3,2%	[$+$0,3; $+$6,2]	0,033
	% intenção indeterminada	+1 ponto	$-$0,8%	[$-$1,3; $-$0,4]	$<$0,001

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 55 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** (C_p, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- Testadas em uma versão anterior do modelo e deixadas de fora (não ajudaram): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

Quem fala o quê

Quem	Slides, na ordem
Kauan	Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com municípios brasileiros; Questão de pesquisa e hipóteses
Fabio	Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil 80 da população
Douglas	Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas
Luiz Felipe	Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado
Willian	Estimativas: efeito de cada variável na taxa; Efeito da renda previsto pelo modelo; Diagnóstico: linearidade e variância; Diagnóstico: normalidade; Diagnóstico: resumo dos testes; Modelo com e sem a renda; Considerações e próximos passos; Obrigado

Glossário rápido

Escopo do modelo	Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam.
Box-Cox	Procedimento que escolhe a potência λ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log.
R^2_a **(ajustado)**	Fração da variação explicada, com penalidade por variável a mais.
Teste F **parcial**	Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda.
VIF	Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave.
Breusch-Pagan	Testa se a variância dos resíduos é constante.
Shapiro-Wilk (W**)**	Testa a normalidade dos resíduos; perto de 1 = mais normal.
Outlier	Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$.
Modelo espacial autorregressivo	Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila.
Modelo multinível	Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila.