Briefing: Luiz Felipe

Fatores associados aos homicídios nos municípios brasileiros

GED-16 · ITA · gerado em 11/11/2026

Você apresenta: Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado.
Antes de você: Douglas. **Depois de você:** Willian.

Sua parte: renda em U, transformação e construção do modelo

Mensagem principal: a relação com a renda é em U invertido; a resposta entra em log (Box-Cox); e o modelo foi montado em blocos, cada um testado pelo F parcial.

O que enfatizar

- **Renda:** nos dados, o pico fica perto de R$ 873; os mais violentos não são os mais pobres nem os mais ricos: são os do 3º décimo de renda, abaixo da renda mediana. Por isso entram renda e renda² (modelo polinomial).
- **Box-Cox:** λ estimado 0,21 (IC 0,15 a 0,26); usamos o log, simples de interpretar. Normalidade: W de 0,93 para 0,99. No slide seguinte, mostrar os gráficos dos resíduos antes e depois: com o log, a dispersão fica mais uniforme e os pontos ficam mais perto da reta.
- **Equação:** cada termo corresponde a uma decisão já mostrada: log da taxa (Box-Cox), renda e renda² (U invertido), Gini e Gini $\times$ renda (o efeito da desigualdade muda com a renda), as demais explicativas e a região (variação entre regiões). Renda e Gini entram centralizados na média.
- **Blocos:** A socioeconômico, B urbanização, C educação e migração, D região, E Gini $\times$ renda. Todos entram; o bloco C dá F parcial 68,0; o maior ganho de R^2_a vem da região (bloco D). O termo Gini $\times$ renda entra por último, com F = 64,6.
- **Região ou estado:** mostrar os dois modelos lado a lado. O estado explica mais (R^2_a 0,64 contra 0,56), mas usa 36 parâmetros e o VIF máximo sobe para 10,6. O termo Gini $\times$ renda e as medidas de escola são significativos nos dois. Dizer que escolhemos a região e que o modelo com estado fica como comparação.

Perguntas prováveis

O λ estimado não é 0, e o 0 está fora do IC; por que usar o log? A apostila recomenda usar um valor de fácil interpretação perto do estimado; o log permite ler os efeitos em %. Dizemos no slide que a escolha é por interpretabilidade.

O que é cada termo da equação? r é o ln da renda centralizado, g é o Gini centralizado, $\mathbf{x}$ são as outras explicativas (desocupação, urbanização, escola e migração), D são as indicadoras de região e ε é o erro, suposto normal, independente e de variância constante.

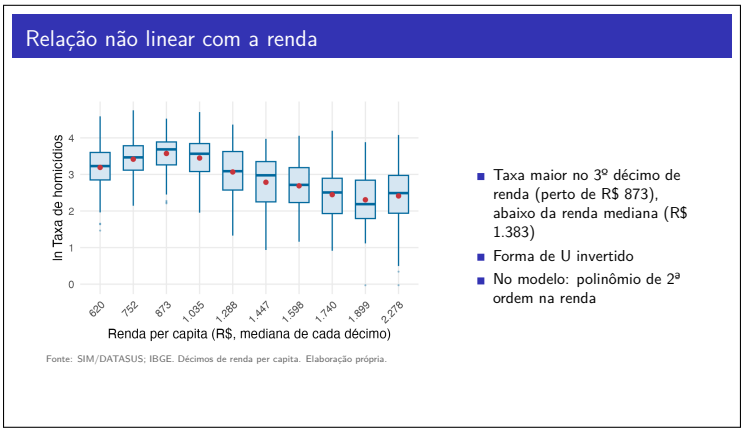
Região ou estado: qual vocês vão usar? A região. A professora pediu para agrupar por região, e esse é o modelo dos outros slides. O modelo com estado fica como comparação. O estado explica mais (F parcial 12,1 com 22 gl), mas tem 36 parâmetros, VIF máximo de 10,6 e 5 estados com menos de 10 municípios.

Transição

"Com o modelo montado, o Willian mostra o que ele diz e como checamos as hipóteses."

Seus slides e o que dizer em cada um

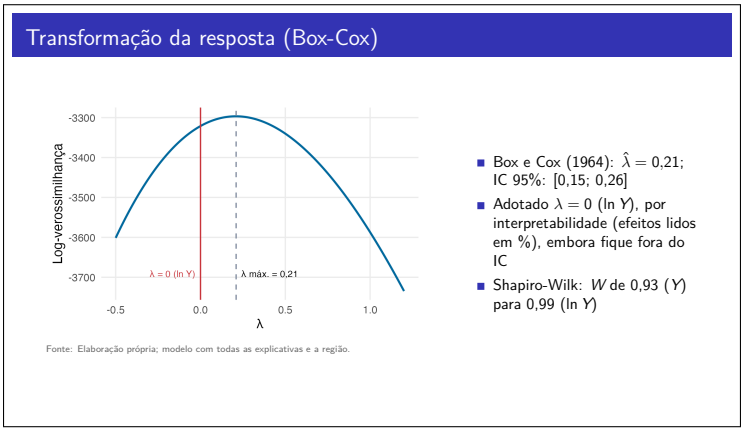
Relação não linear com a renda



O que dizer:

- Cada caixa é um décimo dos municípios por renda.
- Nos dados, a taxa é maior no 3º décimo de renda (perto de R$ 873), abaixo da renda mediana, e cai para os dois lados: isso pede um termo de renda ao quadrado (modelo polinomial de 2a ordem).

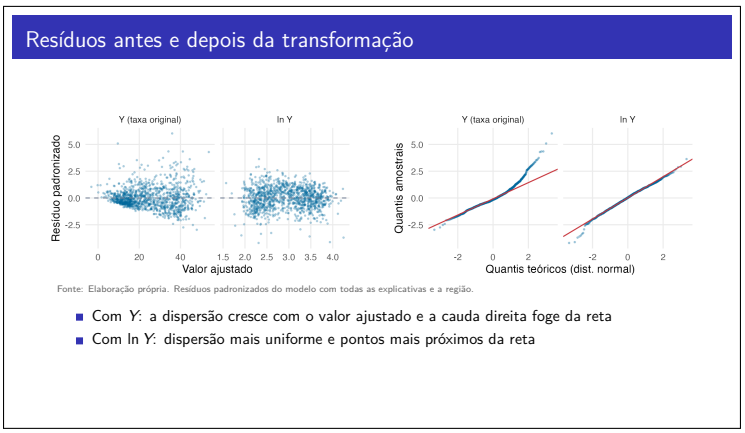
Transformação da resposta (Box-Cox)



O que dizer:

- Box-Cox no modelo múltiplo: lambda estimado 0,21, com IC 95% de 0,15 a 0,26.
- O zero fica fora do intervalo; mesmo assim adotamos o logaritmo (lambda = 0), porque a apostila recomenda um valor de fácil interpretação próximo do estimado e o log permite ler os efeitos em %.
- A normalidade dos resíduos melhora (W de 0,93 para 0,99).

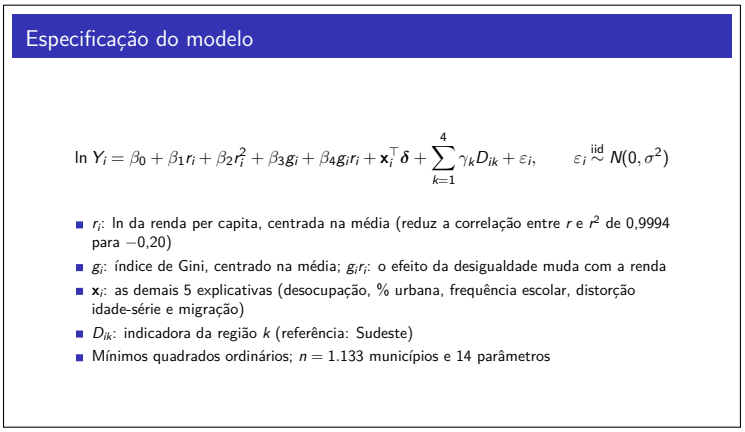
Resíduos antes e depois da transformação



O que dizer:

- Estes são os gráficos dos resíduos antes e depois da transformação.
- Com a taxa original, a dispersão dos resíduos cresce com o valor ajustado, em forma de funil, e no gráfico de quantis a cauda direita foge da reta.
- Com o logaritmo, a dispersão fica mais uniforme e os pontos ficam mais próximos da reta.
- Por isso seguimos com ln(taxa).

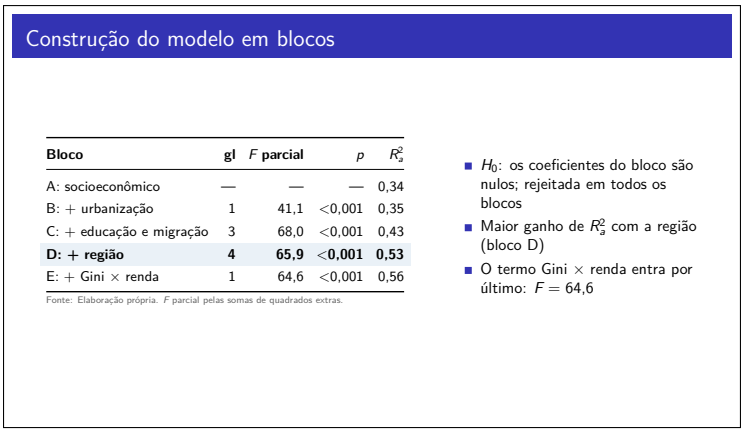
Especificação do modelo



O que dizer:

- Esta é a equação do modelo.
- A resposta é o log da taxa.
- A renda entra centralizada na média e ao quadrado; centralizar reduz a correlação entre renda e renda ao quadrado de 0,9994 para $-0{,}20$.
- O Gini também entra centralizado, e o termo Gini vezes renda deixa o efeito da desigualdade mudar com a renda.
- O vetor x reúne as outras 5 explicativas: desocupação, urbanização, escola e migração.
- As D são as 4 indicadoras de região, com o Sudeste de referência.
- Estimamos por mínimos quadrados ordinários, com 1.133 municípios e 14 parâmetros, supondo erros independentes, normais e de variância constante; o diagnóstico verifica essas hipóteses.

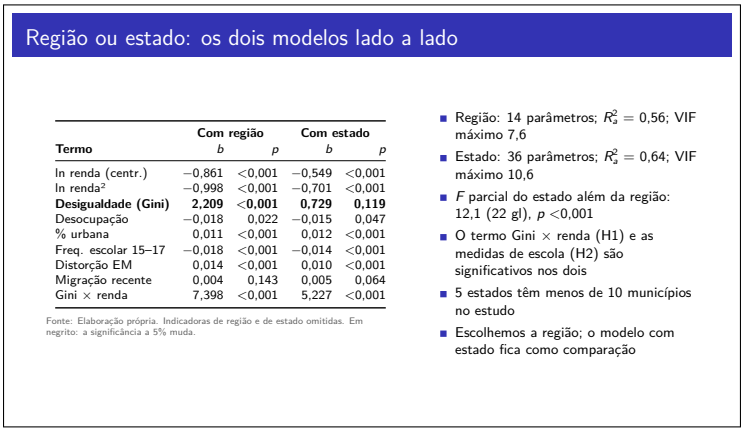
Construção do modelo em blocos



O que dizer:

- Entramos com as variáveis em blocos e testamos cada um pelo F parcial (somas de quadrados extras); a hipótese nula é que os coeficientes do bloco são todos zero, e ela é rejeitada em todos.
- O bloco C, de educação e migração, entra com F parcial 68,0 (R^2 ajustado de 0,35 para 0,43).
- O maior ganho de R^2 ajustado vem da região, o bloco D, o que confirma a diferença entre lugares vista na exploratória.
- O termo Gini vezes renda entra por último, como bloco E, com F de 64,6.

Região ou estado: os dois modelos lado a lado



O que dizer:

- Aqui estão os dois modelos lado a lado: com a região e com o estado.
- O modelo com estado tem 36 parâmetros e R² ajustado de 0,64; o modelo com região tem 14 parâmetros e R² ajustado de 0,56.
- O F parcial do estado além da região é 12,1 com 22 gl: o estado explica mais.
- Em troca, o VIF máximo sobe para 10,6 e 5 estados têm menos de 10 municípios no estudo.
- O termo Gini vezes renda e as medidas de escola são significativos nos dois modelos.
- Escolhemos a região: o modelo é mais simples e as conclusões são as mesmas.
- O modelo com estado fica como comparação.

O projeto em um minuto

Pergunta: quais características socioeconômicas, demográficas e geográficas estão associadas à taxa de homicídios nos municípios brasileiros?

- **Tema:** ODS 16 (paz e justiça), indicador 16.1.1: homicídios por 100 mil habitantes.
- **Contexto:** 46.105 homicídios por ano; taxa 3,9 vezes a média mundial (UNODC); Norte e Nordeste bem acima de Sudeste e Sul.
- **Literatura:** os estudos nacionais com municípios (Wanzinack et al., 2022; Barros et al., 2020; Aransiola et al., 2022; Castellucci e Silva, 2026) usam dados de 2010. Nós usamos o Censo 2022 completo.
- **Unidade de análise:** o município. São 5.570 municípios, com 138.316 homicídios em 2021–2023 (22,7 por 100 mil hab./ano).
- **Resposta:** taxa de homicídios (agressão + intervenção legal, por residência da vítima), média de 2021 a 2023, do SIM/DATASUS.
- **Explicativas:** Censo 2022 do IBGE (renda, desigualdade, trabalho, frequência escolar, urbanização, idade, migração), INEP 2022 (distorção idade-série no ensino médio), mais região.
- **Modelo:** regressão linear múltipla para ln(taxa), por mínimos quadrados, nos 1.133 municípios com 30 mil habitantes ou mais (Campos do Jordão-SP ficou fora por indício de sub-registro).

As decisões e o porquê de cada uma

Decisão	Por quê	Apostila
Violência medida pela taxa de homicídios do SIM	Indicador 16.1.1 do ODS 16; estatística de violência local mais confiável do país e correlacionada com outros crimes (Murray et al., 2013); o SIM cobre todos os municípios com a mesma codificação (CID-10). Pela residência da vítima, média de 2021–2023	—
Escopo: municípios com 30 mil hab. ou mais	Nos pequenos o homicídio é raro: abaixo de 5 mil hab. a mediana é 1 caso em 3 anos e a taxa oscila $\pm$66% só pelo acaso; 655 municípios têm taxa zero. O corte fica perto do percentil 80 da população (pedido da professora: percentil por município): a partir dele não há nenhum zero e há pelo menos 20 homicídios esperados em 3 anos. Ficam 1.133 municípios (77% da população)	Cap. 1: escopo do modelo
Campos do Jordão-SP fora do estudo	Indício de sub-registro: 1 homicídio registrado e 36 óbitos de intenção indeterminada em 3 anos	—
Densidade fora do modelo	Pedido da professora: padronizar a densidade e tirar os extremos, porque o desvio-padrão era muito maior que a média. Com o corte de 30 mil hab., a densidade (em ln, padronizada) não é significativa: F = 0,08, p = 0,78. Ela sai do modelo, e não é preciso cortar municípios por densidade	Cap. 6: F parcial e padronização
Resposta em ln(taxa)	Box-Cox estimou λ = 0,21 (IC de 0,15 a 0,26); usamos $\lambda = 0$, simples de interpretar, mesmo fora do IC. A normalidade melhora (W de 0,93 para 0,99)	Cap. 4: Box-Cox
Só a renda (sem % pobres e alfabetização)	As três medem quase o mesmo: VIF da renda 16 e sinais contraditórios	Cap. 6: multicolinearidade e VIF
Renda e renda², com a renda centralizada	No Gini médio, a taxa sobe até uma renda de cerca de R$ 815 (abaixo da renda mediana) e depois cai (U invertido); centralizar evita a colinearidade entre X e X^2	Cap. 7: modelos polinomiais
Renda mantida, depois de comparar o modelo com e sem ela	Pedido da professora, por causa do VIF da renda (7,6). F parcial da renda 74,5 (3 gl); sem ela o R^2_a cai de 0,56 para 0,47. Sem a renda sai também o termo Gini $\times$ renda; a desigualdade e a desocupação deixam de ser significativas, e as medidas de escola continuam	Cap. 6: multicolinearidade e F parcial
Termo Gini $\times$ renda	O efeito da desigualdade muda com a renda: F = 64,6, R^2_a de 0,53 para 0,56. Na renda mediana, +0,05 no Gini dá $+$16% na taxa; nos 10% mais ricos, $+$34%; abaixo de R$ 931 (29% dos municípios) o efeito não é positivo. O Gini entra centralizado	Cap. 7: modelos com interação
Região (5 classes) como variável categórica	Pedido da professora: agrupar os municípios por região do Brasil. Entram 4 indicadoras, com o Sudeste de referência. É o bloco D, com maior ganho de R^2_a. **Entre região e estado, o grupo escolheu a região**: um slide mostra os dois modelos lado a lado, e o modelo com estado fica como comparação (com estado: 36 parâmetros, R^2_a 0,64, VIF máximo 10,6)	Cap. 6 e 7: F parcial, variáveis categóricas
Bloco C: educação e migração	Frequência escolar 15–17, distorção idade-série e migração recente; a frequência foi a mais forte entre 26 candidatas testadas em uma versão anterior do modelo. F parcial 68,0 e R^2_a de 0,35 para 0,43	Cap. 6: F parcial
Amazônia Legal testada e fora do	A maior parte dela é a própria região Norte, que já está no	—

O que o modelo mostra

- O modelo explica 0,56 da variação do ln(taxa) (R^2_a); F global = 111 com 13 e 1.119 gl.
- **Renda em U invertido:** no Gini médio, a taxa esperada é máxima com renda per capita de cerca de R$ 815 e cai nos mais pobres e nos mais ricos.
- **Mais homicídios** com mais desigualdade (nos municípios de renda média e alta, não nos mais pobres), mais urbanização e mais atraso escolar; **menos** com mais jovens de 15–17 na escola e, sem explicação testada, com mais desocupação (efeitos em % na tabela abaixo).
- **Não significativa** no modelo atual: migração recente. A hipótese H3 não é confirmada.

Hip.	Variável	Mudança	Taxa	IC 95%	p
	Renda	—	U invertido	—	<0,001
H1	Gini (renda de R$ 699)	+0,05	−10,0%	[−16,8; −2,8]	0,008
H1	Gini (renda de R$ 1.383)	+0,05	+15,8%	[+10,6; +21,3]	<0,001
H1	Gini (renda de R$ 2.043)	+0,05	+33,7%	[+26,3; +41,7]	<0,001
H2	Distorção idade-série (EM)	+10 pontos	+15,6%	[+11,5; +19,8]	<0,001
	% urbana	+10 pontos	+11,8%	[+8,3; +15,4]	<0,001
H2	Frequência escolar 15–17	+5 pontos	−8,6%	[−11,9; −5,3]	<0,001
	Desocupação	+1 ponto	−1,8%	[−3,3; −0,3]	0,022

Efeito = variação da taxa para a mudança indicada, com as demais variáveis constantes ($100\,[\exp(b\,\Delta) - 1]\%$ com a resposta em log), com o IC 95% ao lado.

O que ainda não está resolvido

- **Variância não constante:** Breusch-Pagan = 46 (rejeita). Os coeficientes continuam certos na média, mas os valores p ficam aproximados.
- **Seleção de variáveis** (C_p, AIC, BIC, PRESS) ainda não foi feita: é da entrega final.
- Testadas em uma versão anterior do modelo e deixadas de fora (não ajudaram): garimpo, desmatamento, Bolsa Família, mães solo e gasto municipal em segurança e assistência (SICONFI 2022).

Quem fala o quê

Quem	Slides, na ordem
Kauan	Capa; Roteiro; Homicídios no Brasil; Estudos anteriores com municípios brasileiros; Questão de pesquisa e hipóteses
Fabio	Fontes de dados; Medida de violência: taxa de homicídios; Variáveis explicativas; Limitações dos dados; Municípios considerados: percentil 80 da população
Douglas	Resumo das variáveis; Distribuição da variável resposta; Variação entre regiões; Correlação linear com ln(taxa); Correlação entre as explicativas
Luiz Felipe	Relação não linear com a renda; Transformação da resposta (Box-Cox); Resíduos antes e depois da transformação; Especificação do modelo; Construção do modelo em blocos; Região ou estado: os dois modelos lado a lado
Willian	Estimativas: efeito de cada variável na taxa; A desigualdade depende da renda; Efeito da renda previsto pelo modelo; Diagnóstico: linearidade e variância; Diagnóstico: normalidade; Diagnóstico: resumo dos testes; Modelo com e sem a renda; Considerações e próximos passos; Obrigado

Glossário rápido

Escopo do modelo	Faixa de dados em que o modelo vale. Fora dela, as conclusões não se aplicam.
Box-Cox	Procedimento que escolhe a potência λ da resposta que deixa o modelo mais perto das hipóteses; $\lambda = 0$ é o log.
R^2_a **(ajustado)**	Fração da variação explicada, com penalidade por variável a mais.
Teste F **parcial**	Compara o modelo com e sem um bloco de variáveis: diz se o bloco ajuda.
VIF	Mede o quanto uma variável repete as outras (multicolinearidade). Acima de 10 é grave.
Breusch-Pagan	Testa se a variância dos resíduos é constante.
Shapiro-Wilk (W**)**	Testa a normalidade dos resíduos; perto de 1 = mais normal.
Outlier	Resíduo semi-studentizado com $\lvert e^* \rvert \geq 4$.
Modelo espacial autorregressivo	Regressão em que a taxa de um município depende também da taxa dos vizinhos (usado por Barros et al.). Fora da apostila.
Modelo multinível	Regressão com municípios agrupados em estados, separando a variação entre e dentro dos estados (usado por Castellucci e Silva). Fora da apostila.